

데이터 처리 가이드

이 문서는 HBS_articles.csv / HBS_articles_ko.csv를 NLP 파이프라인에 통합하기 위한 처리 기준과 단계별 방법을 설명합니다. 기존 DBR / HBR 처리 방식을 기준으로 작성되었습니다.

1. 데이터 파일 개요

파일명	건수	설명
HBS_articles.csv	2,116건	HBS Working Knowledge 영어 원문. title / content / summary / url / category / published_date / source 컬럼 포함.
HBS_articles_ko.csv	2,116건	영어 원문에 한국어 번역 컬럼을 추가한 파일. title_ko / summary_ko / content_ko_summary 포함. 번역 실패 0건.

2. CSV 컬럼 설명

■ HBS_articles.csv (원문)

컬럼명	설명
title	기사 제목 (영어)
content	기사 본문 (영어, 평균 1,000~3,000자)
summary	기사 요약 또는 메타 description (영어)
url	원문 URL (HBS Working Knowledge)
category	카테고리 (Strategy & Innovation / Leadership / Data & Technology 등 12개)
published_date	게시일 (YYYY-MM-DD 형식, 일부 YYYY-01-01)
source	데이터 출처 — 고정값 'HBS'

■ HBS_articles_ko.csv (번역본 추가 컬럼)

컬럼명	설명
title_ko	제목 한국어 번역 (Google Translate)
summary_ko	요약 한국어 번역

content_ko_summary	본문 앞 500자 한국어 번역 (전체 번역 대신 핵심 요약용)
--------------------	------------------------------------

3. 기존 DBR / HBR 처리 파이프라인 (참고)

DBR(11,273건) + HBR(2,062건) + NAVER(55,465건) 데이터는 아래 5단계 파이프라인으로 처리되었습니다.
HBS 처리 시 동일한 흐름을 따르되 영어 특성에 맞게 수정합니다.

단계	처리 내용
① 전처리	Kiwi 형태소 분석 → NNG/NNP/VV/VA 품사 필터 → 불용어 220개 제거 산출물: DBR_preprocessed.parquet / HBR_preprocessed.parquet
② 라벨링	Stage 1: 성공/실패 키워드 히트 → success_ratio (≥0.65 성공 / ≤0.35 실패) Stage 2: TF-IDF 센트로이드 코사인 유사도 재분류 (모호 → neutral) 산출물: label(success/failure/neutral), confidence 컬럼
③ SBERT 임베딩	모델: jhgan/ko-sroberta-multitask (768차원, 한국어 특화) DBR+HBR+NAVER → 임베딩 생성 → FAISS IndexFlatIP 구축
④ 리스크 모델	MLP (hidden=512×128) — Test AUC 0.9771, Failure F1 0.78 risk_score = P(failure embedding), class_weight='balanced'
⑤ UMAP+K-means	768차원 임베딩 → UMAP 2D → K-means 12클러스터 산출물: umap_coords_v3.parquet, cluster_info_v3.parquet

4. HBS 데이터 처리 방법

HBS 기사는 영어이므로 기존 Kiwi 기반 전처리를 그대로 쓸 수 없습니다. 아래 두 가지 선택지 중 하나를 팀 상황에 맞게 선택하세요.

[선택지 A] 한국어 번역 컬럼 활용 — 권장

HBS_articles_ko.csv의 title_ko + summary_ko + content_ko_summary를 사용해 기존 DBR/HBR 파이프라인(Kiwi 전처리)을 그대로 적용합니다.

장점	단점
기존 코드 재사용 가능 (preprocess.py 수정 최소화) Kiwi 형태소 분석기 그대로 사용 DBR/HBR과 동일한 임베딩 공간에서 FAISS 검색 가능	번역 과정에서 일부 뉘앙스 손실 가능 content_ko_summary는 500자 요약이므로 전체 내용 미반영

처리 대상 텍스트: title_ko + ' ' + summary_ko + ' ' + content_ko_summary 합치기
이후 preprocess.py의 Kiwi 분석 적용 (기존과 동일)
라벨링, 임베딩, FAISS 통합도 기존 스크립트 그대로 사용 가능

[선택지 B] 영어 원문 직접 처리

HBS_articles.csv의 content + summary 영어 원문을 NLTK로 전처리 후 multilingual SBERT로 임베딩합니다.

장점	단점
원문 정보 100% 보존 paraphrase-multilingual-MiniLM-L12-v2 모델이 영어 지원	전처리 코드 별도 작성 필요 (NLTK 설치) 영어/한국어 혼합 인덱스에서 검색 품질 저하 가능

5. 단계별 처리 상세 가이드 (선택지 A 기준)

① 전처리

기존 preprocess.py를 참고하여 HBS용 전처리 코드를 작성합니다.

```
# HBS (선택지 A: )
import pandas as pd
from kiwipiepy import Kiwi

df = pd.read_csv('HBS_articles_ko.csv')
#
df['text'] = df['title_ko'].fillna('') + ' ' + df['summary_ko'].fillna('') + ' ' +
df['content_ko_summary'].fillna('')
# preprocess.py Kiwi
```

출력: HBS_preprocessed.parquet (clean_text, tokens, token_str, n_tokens 컬럼 포함)
category 컬럼은 영어 그대로 저장 (Strategy & Innovation 등)
source 컬럼 값 = 'HBS' — articles 테이블 삽입 시 그대로 사용

② 라벨링

기존 label.py의 성공/실패 키워드 사전과 TF-IDF 방식을 그대로 사용합니다. 단, HBS 기사는 경영학 사례 중심이므로 키워드 히트율이 DBR보다 낮을 수 있습니다.

라벨	기준	참고 DBR 비율
success	success_ratio $\geq$ 0.65 (키워드 히트 최소 3개)	86.9%
failure	success_ratio $\leq$ 0.35 (키워드 히트 최소 3개)	4.7%
neutral	중간값 또는 히트 부족 → TF-IDF Stage 2 재분류	8.3%

출력: HBS_labeled.parquet (label, confidence 컬럼 추가)
failure 비율이 낮을 경우 Stage 2 sim_threshold를 0.10으로 낮춰 시도
label.py 실행 시 --source HBS 인자 지원하면 소스별 분리 가능

③ SBERT 임베딩 + FAISS 통합

기존 embed.py는 DBR+HBR을 처리합니다. HBS를 기존 FAISS 인덱스에 추가하거나 별도 인덱스를 만드는 두 방식 중 선택하세요.

방식	설명	권장
----	----	----

기존 인덱스에 추가	HBS_labeled.parquet을 DBR+HBR과 합쳐 embed.py 재실행 → 하나의 faiss.index 생성 articles_meta.parquet에 HBS 행 추가	권장
별도 인덱스 생성	HBS 전용 faiss_hbs.index 생성 → ai_server에서 두 인덱스 동시 검색	복잡도 증가

사용 모델: jhgan/ko-sroberta-multitask (768차원) — 한국어 번역 텍스트에 적합

기존 인덱스 추가 시 embeddings.npy도 np.vstack으로 합치기

FAISS write_index() 한글 경로 버그 — faiss.serialize_index() + Path.write_bytes() 사용

④ 리스크 모델 재학습 (선택)

기존 risk_model.pkl은 DBR+HBR+NAVER 68,800건으로 학습되었습니다. HBS 2,116건을 추가하면 소폭 성능 향상이 기대되지만 재학습은 선택 사항입니다.

재학습 시: neutral 제외, class_weight='balanced', 5-fold stratified CV 유지

현재 모델 성능: Test AUC 0.9771 / Failure F1 0.78 — 재학습 없어도 충분

재학습 스크립트: 데이터처리/risk_model.py

⑤ DB 임포트

기존 import_articles_to_db.py를 HBS 데이터에도 적용합니다.

테이블	삽입 내용
articles	title(=title_ko 권장 또는 title 영어), content, summary, url, source='HBS', category, published_date
article_labels	label(success/failure/neutral), label_method='auto', confidence
article_vectors	embedding_vector(JSON), umap_x, umap_y, cluster_id

article_no = URL MD5 해시 20자 (import_articles_to_db.py 기존 로직 동일)

url 기준 중복 스킵 → 재실행 안전

articles.title 컬럼 길이(VARCHAR) 확인 — HBS 제목이 길 경우 초과 주의

6. 주의사항 및 체크리스트

항목	내용
인코딩	HBS_articles_ko.csv는 UTF-8. open() 시 encoding='utf-8' 필수
빈 컬럼	일부 기사의 content가 짧을 수 있음 (100자 미만 필터됨). n_tokens 확인
날짜 형식	published_date가 YYYY-01-01 형태인 기사 존재 (연도만 확인된 경우)
카테고리	Social Responsibility, Artificial Intelligence는 0건 — 다른 카테고리 URL 중복
Leadership	11건 수집 — HBS 사이트에서 해당 컬렉션 기사 수가 적음
FAISS 경로	한글 경로 사용 불가 — serialize_index() 방식으로 저장

DB charset	campus.smhrd.com DB는 latin1 기반 — db.js에 charset 옵션 절대 추가 금지
------------	---

7. 빠른 실행 순서 (체크리스트)

1	HBS_articles_ko.csv 파일 확인 (크롤링/ 폴더)
2	preprocess.py 수정 — 번역 컬럼(title_ko + summary_ko + content_ko_summary) 합치기 후 Kiwi 분석
3	python 데이터처리/preprocess.py --source HBS 실행 → HBS_preprocessed.parquet 생성
4	python 데이터처리/label.py --source HBS 실행 → HBS_labeled.parquet 생성 (label/confidence)
5	embed.py에 HBS_labeled.parquet 추가 후 재실행 → 기존 FAISS 인덱스에 통합
6	python 데이터처리/import_articles_to_db.py --source HBS 실행 → articles/article_labels 테이블 삽입
7	(선택) risk_model.py 재학습 — HBS 포함 전체 데이터셋으로
8	(선택) umap_cluster_v3.py 재실행 → article_vectors umap_x/y/cluster_id 업데이트